

Projeto de Engenharia de Dados — Arquitetura Medalhão

Análise de Desempenho Acadêmico de Estudantes

Universidade do Oeste Paulista

Sistemas de Informação

Tópicos Especiais Em Sistemas De Informação 1

Alunos:

- Diego Vinicius Brito Matricardi — RA: 262124858
 - Felipe Huss Mendes Pereira — RA: 262216051
 - Victor Taveira Rodrigues — RA: 261911759
-

Presidente Prudente – SP, 2026

Sumário

1. [Contexto e Objetivo](#)
 2. [Dataset Utilizado](#)
 3. [Instalação do Projeto](#)
 4. [Arquitetura Medalhão](#)
 5. [Camada Bronze](#)
 6. [Camada Silver](#)
 7. [Camada Gold](#)
 8. [Resultados e KPIs](#)
 9. [Validação das Hipóteses](#)
 10. [Conclusão](#)
-

1. Contexto e Objetivo

A dificuldade das instituições de ensino em **identificar antecipadamente alunos com baixo desempenho acadêmico** é um problema real e recorrente. Quando o problema é

percebido, muitas vezes já é tarde para intervenções eficazes, resultando em reprovação ou queda no rendimento escolar.

Este projeto aplica a **Arquitetura Medalhão** de Engenharia de Dados sobre um dataset de desempenho de estudantes do ensino médio, com o objetivo de:

- Organizar e qualificar os dados seguindo boas práticas de engenharia de dados
- Calcular KPIs de negócio que permitam identificar padrões de desempenho
- Validar hipóteses sobre os fatores que influenciam o rendimento acadêmico
- Subsidiar intervenções pedagógicas baseadas em dados

Stakeholders principais:

Stakeholder	Interesse
Gestores e diretores escolares	Acompanhar indicadores educacionais
Professores e coordenadores pedagógicos	Realizar intervenções educacionais
Secretarias de educação	Melhorar o desempenho geral dos alunos

2. Dataset Utilizado

Nome: Students Performance Dataset
Fonte: [Kaggle — Rabie El Kharoua](#)
Licença: CC BY 4.0
Tipo: Dataset sintético educacional
Registros: 2.392 alunos
Arquivo: `data/student_performance_dataset.csv`

Descrição das colunas

Coluna	Tipo	Descrição
StudentID	int	Identificador único do aluno (1001–3392)
Age	int	Idade do aluno (15–18 anos)
Gender	int	Gênero: 0 = Masculino, 1 = Feminino
Ethnicity	int	Etnia (removida na Silver — ver seção 6)
ParentalEducation	int	Nível educacional dos pais (0–4)
StudyTimeWeekly	float	Horas de estudo por semana (0–20h)
Absences	int	Número de faltas no ano (0–30)
Tutoring	int	Aulas particulares: 0 = Não, 1 = Sim

Coluna	Tipo	Descrição
ParentalSupport	int	Nível de suporte parental (0–4)
Extracurricular	int	Atividades extracurriculares: 0 = Não, 1 = Sim
Sports	int	Prática de esportes: 0 = Não, 1 = Sim
Music	int	Atividades musicais: 0 = Não, 1 = Sim
Volunteering	int	Voluntariado: 0 = Não, 1 = Sim
GPA	float	Média acadêmica (0.0–4.0)
GradeClass	int	Classe de nota-alvo (0=A, 1=B, 2=C, 3=D, 4=F)

3. Instalação do Projeto

Pré-requisitos

- Python 3.10 ou superior
- pip

Passos

```
# 1. Clone ou acesse o diretório do projeto
cd /caminho/para/eng_dados

# 2. Crie e ative o ambiente virtual (recomendado)
python3 -m venv .venv
source .venv/bin/activate    # Linux/macOS
.venv\Scripts\activate      # Windows

# 3. Instale as dependências via requirements.txt
pip install -r requirements.txt

# 4. Registre o kernel Jupyter
python -m ipykernel install --user --name python3

# 5. Execute os notebooks em sequência
jupyter nbconvert --to notebook --execute --inplace src/students_performance/bronze.ipynb
jupyter nbconvert --to notebook --execute --inplace src/students_performance/silver.ipynb
jupyter nbconvert --to notebook --execute --inplace src/students_performance/gold.ipynb
```

Estrutura de arquivos

```
eng_dados/
├── requirements.txt           ← Dependências do projeto
├── data/
│   ├── student_performance_dataset.csv ← Dataset original
│   └── data_lakehouse.db       ← SQLite (gerado automaticamente)
├── src/
│   └── students_performance/
│       ├── bronze.ipynb      ← Camada Bronze
│       ├── silver.ipynb     ← Camada Silver
│       └── gold.ipynb        ← Camada Gold
└── docs/
    ├── gerar_pdf.py          ← Script de geração do PDF
    ├── relatorio_students_performance.md ← Este relatório
    └── relatorio_students_performance.pdf ← PDF gerado pelo script
```

Dependências (`requirements.txt`)

Pacote	Versão mínima	Finalidade
<code>pandas</code>	2.0.0	Manipulação e análise de dados
<code>numpy</code>	1.24.0	Operações numéricas
<code>jupyter</code>	1.0.0	Ambiente de notebooks
<code>nbconvert</code>	7.0.0	Execução e conversão dos notebooks
<code>ipykernel</code>	6.0.0	Kernel Python para Jupyter
<code>markdown</code>	3.5.0	Conversão de Markdown para HTML
<code>weasyprint</code>	60.0	Geração de PDF a partir de HTML

`sqlite3` já está incluso na biblioteca padrão do Python — não requer instalação separada.

Gerar o PDF


Com o ambiente virtual ativado, execute a partir da raiz do projeto:

```
python docs/gerar_pdf.py
```

O script (`docs/gerar_pdf.py`) lê o arquivo Markdown deste relatório, converte para HTML via `markdown` e gera o PDF via `weasyprint` . O PDF é salvo em `docs/relatorio_students_performance.pdf` .

4. Arquitetura Medalhão

A **Arquitetura Medalhão** (Medallion Architecture) é um padrão de design para organização de dados em um lakehouse. Proposta e popularizada pela Databricks, ela organiza os dados em camadas progressivas de qualidade, nomeadas por analogia a medalhas olímpicas:



Princípios da arquitetura

Princípio	Descrição
Imutabilidade da Bronze	Os dados brutos nunca são modificados; qualquer erro é corrigido na Silver
Progressão de qualidade	Cada camada adiciona valor sem destruir a anterior
Rastreabilidade	É possível rastrear qualquer registro da Gold até sua origem na Bronze
Separação de responsabilidades	Cada camada tem uma única função bem definida
Governança	Regras de qualidade e compliance (LGPD) são aplicadas na Silver

Implementação neste projeto

Neste projeto, o lakehouse é simulado com um banco **SQLite** (`data_lakehouse.db`), seguindo o mesmo padrão adotado no projeto de vendas (`clients_products_sells`). Em produção, esse banco seria substituído por Delta Lake, Apache Iceberg ou um serviço de nuvem como Azure Data Lake / Databricks.

5. Camada Bronze

Arquivo: `src/students_performance/bronze.ipynb`

Responsabilidade

Ingestão fiel e sem transformações do dataset original. A camada Bronze representa a "zona de pouso" dos dados, garantindo que a versão bruta seja sempre preservada para auditoria, reprocessamento e rastreabilidade.

O que o notebook faz

1. **Importa** as bibliotecas `pandas` e `sqlite3`
2. **Estabelece conexão** com o banco SQLite `data/data_lakehouse.db`
3. **Lê** o arquivo `data/student_performance_dataset.csv` com `pandas.read_csv()`
4. **Inspecciona** os dados: shape, tipos de colunas, valores nulos e duplicatas
5. **Grava** o DataFrame na tabela `bronze_students` via `to_sql()` com `if_exists="replace"`
6. **Valida** a gravação consultando a contagem de registros

Tabela gerada

Tabela	Registros	Colunas	Tratamento
<code>bronze_students</code>	2.392	15	Nenhum — dados brutos

Diagnóstico da Bronze

A inspeção inicial revelou:

- **2.392 registros e 15 colunas**
- **0 valores nulos** em nenhuma coluna
- **0 linhas duplicadas** completas
- **0 StudentIDs duplicados**
- Todos os tipos são numéricos (int/float), adequados para processamento

Observação: A ausência de nulos e duplicatas é esperada em datasets sintéticos como este. Em dados reais, problemas de qualidade seriam mais frequentes e seriam todos tratados na camada Silver.

6. Camada Silver

Arquivo: `src/students_performance/silver.ipynb`

Responsabilidade

Limpeza, validação, padronização e enriquecimento dos dados da Bronze. A Silver é a camada confiável para análises — os dados já foram tratados e estão prontos para modelagem dimensional.

O que o notebook faz

1. Remoção da coluna `Ethnicity`

A coluna `Ethnicity` é **removida nesta camada** por dois motivos complementares:

a) LGPD (Lei Geral de Proteção de Dados — Lei 13.709/2018):

Etnia é classificada como **dado sensível** pela LGPD, exigindo consentimento explícito e cuidado especial no tratamento. Em conformidade com a lei, optamos por não persistir esse dado nas camadas analíticas.

b) Fairness / Equidade Algorítmica:

A análise da distribuição revelou forte desbalanceamento:

Etnia (código)	Registros
0 — Caucasiano	majoritário
1 — Afro-americano	minoría
2 — Asiático	minoría
3 — Outro	minoría

Esse desbalanceamento poderia induzir viés no modelo preditivo, gerando previsões injustas para grupos minoritários e decisões discriminatórias.

Princípio aplicado: A coluna é removida **na Silver** (e não na Bronze), pois a Bronze deve preservar o dado original. Qualquer decisão de exclusão é feita nas camadas de transformação.

2. Validação e correção de tipos

Coluna	Tipo esperado	Ação
<code>StudentID</code> , <code>Age</code> , <code>Gender</code> , etc.	<code>int</code>	Conversão via <code>pd.to_numeric</code>
<code>StudyTimeWeekly</code> , <code>GPA</code>	<code>float</code>	Conversão via <code>pd.to_numeric</code>
<code>GradeClass</code>	<code>int</code>	Conversão de <code>float</code> (ex: <code>2.0</code>) para <code>int</code>

3. Tratamento de nulos e duplicatas

- Linhas com `StudentID` , `GPA` ou `GradeClass` nulos são removidas
- Duplicatas por `StudentID` são removidas (mantendo a primeira ocorrência)

4. Validação de intervalos

Todos os campos foram validados contra os intervalos documentados no dataset:

Campo	Intervalo	Status
Age	15–18	✓ OK
Gender	0–1	✓ OK
ParentalEducation	0–4	✓ OK
StudyTimeWeekly	0–20	✓ OK
Absences	0–30	✓ OK
GPA	0.0–4.0	✓ OK
GradeClass	0–4	✓ OK

5. Decodificação de colunas categóricas

Colunas `_label` foram adicionadas para legibilidade humana, sem remover os valores numéricos originais:

Coluna	Coluna Label	Mapeamento
<code>Gender</code>	<code>Gender_label</code>	0 → Masculino, 1 → Feminino
<code>ParentalEducation</code>	<code>ParentalEducation_label</code>	0 → Nenhum ... 4 → Pós-Graduação
<code>ParentalSupport</code>	<code>ParentalSupport_label</code>	0 → Nenhum ... 4 → Muito Alto
<code>Tutoring</code>	<code>Tutoring_label</code>	0 → Não, 1 → Sim
<code>Extracurricular</code>	<code>Extracurricular_label</code>	0 → Não, 1 → Sim
<code>Sports</code>	<code>Sports_label</code>	0 → Não, 1 → Sim

Coluna	Coluna Label	Mapeamento
Music	Music_label	0 → Não, 1 → Sim
Volunteering	Volunteering_label	0 → Não, 1 → Sim
GradeClass	GradeClass_label	0 → A, 1 → B, 2 → C, 3 → D, 4 → F

Tabela gerada

Tabela	Registros	Colunas
silver_students	2.392	22 (14 originais – Ethnicity + 8 labels)

7. Camada Gold

Arquivo: `src/students_performance/gold.ipynb`

Responsabilidade

Modelagem dimensional e geração de KPIs prontos para consumo analítico. A camada Gold organiza os dados em tabelas otimizadas para consulta, seguindo o modelo estrela (star schema) com dimensões e tabela fato.

O que o notebook faz

Modelagem dimensional

`dim_aluno` — Dimensão com dados descritivos do aluno:

```
dim_aluno
├── StudentID (PK)
├── Age
├── Gender / Gender_label
├── ParentalEducation / ParentalEducation_label
├── ParentalSupport / ParentalSupport_label
```

`fato_desempenho` — Tabela fato com indicadores mensuráveis:

```
fato_desempenho
├── StudentID (FK → dim_aluno)
├── StudyTimeWeekly
├── Absences
├── Tutoring / Tutoring_label
├── Extracurricular / Extracurricular_label
├── Sports / Sports_label
├── Music / Music_label
├── Volunteering / Volunteering_label
├── GPA
├── GradeClass / GradeClass_label
```

Tabelas KPI geradas

Tabela Gold	Descrição	Hipóteses relacionadas
gold_distribuicao_gradeclasse	Contagem e % por classe de nota	KPI de negócio
gold_taxa_aprovacao	Aprovados vs Reprovados/Em Risco	KPI de negócio
gold_gpa_por_suporte_parental	GPA médio por nível de suporte familiar	H4
gold_gpa_por_educacao_pais	GPA médio por nível educacional dos pais	H5
gold_gpa_por_tutoria	GPA médio com/sem aulas particulares	H10
gold_gpa_por_extracurricular	GPA médio com/sem atividades extracurriculares	H3
gold_gpa_faixas_estudo	GPA médio por faixa de horas de estudo	H1, H8
gold_gpa_faixas_faltas	GPA médio por faixa de faltas	H2, H6
gold_gpa_por_idade	GPA médio por idade	H7
gold_gpa_perfil_dedicado	GPA para alunos dedicados vs demais	H8, H9
gold_correlacao_com_gpa	Correlação de Pearson de cada variável com GPA	H1–H10
gold_hipoteses_mapeadas	Mapeamento das hipóteses para tabelas Gold	Todas

8. Resultados e KPIs

8.1 Estatísticas gerais

Métrica	Valor
Total de alunos	2.392
GPA Médio	1,9062
GPA Mediana	1,8934
Desvio Padrão do GPA	0,9152

8.2 Distribuição por classe de nota

GradeClass	Descrição	Quantidade	Percentual
A	$GPA \geq 3,5$	107	4,47%
B	$3,0 \leq GPA < 3,5$	269	11,25%
C	$2,5 \leq GPA < 3,0$	391	16,35%
D	$2,0 \leq GPA < 2,5$	414	17,31%
F	$GPA < 2,0$	1.211	50,63%

Destaque: Mais da metade dos alunos (50,63%) estão na classe F, com GPA abaixo de 2,0. Isso indica uma distribuição fortemente assimétrica e reforça a urgência de intervenções pedagógicas.

8.3 Taxa de aprovação vs reprovação

Situação	Quantidade	Percentual
Aprovado (A, B ou C)	767	32,07%
Reprovado/Em Risco (D ou F)	1.625	67,93%

KPI crítico: Apenas **1 em cada 3 alunos** alcança nota de aprovação. Esse é o principal indicador de negócio que justifica o projeto.

8.4 GPA médio por nível de suporte parental

Suporte Parental	GPA Médio	Qtd. Alunos
Nenhum	1,5401	212
Baixo	1,7557	489
Moderado	1,8842	740
Alto	2,0424	697
Muito Alto	2,1915	254

8.5 GPA médio por educação dos pais

Educação dos Pais	GPA Médio	Qtd. Alunos
Nenhum	1,8930	243
Ensino Médio	1,9440	728
Faculdade Incompleta	1,9299	934
Bacharelado	1,8091	367
Pós-Graduação	1,8158	120

8.6 GPA médio por tutoria (aulas particulares)

Tutoria	GPA Médio	Qtd. Alunos
Não	1,8190	1.671
Sim	2,1083	721

8.7 GPA médio por atividades extracurriculares

Extracurricular	GPA Médio	Qtd. Alunos
Não	1,8383	1.475
Sim	2,0154	917

8.8 GPA médio por faixa de horas de estudo semanais

Faixa de Estudo	GPA Médio	Qtd. Alunos
0–5 horas	1,6916	595
5–10 horas	1,8491	643

Faixa de Estudo	GPA Médio	Qtd. Alunos
10–15 horas	1,9990	619
15–20 horas	2,1059	535

8.9 GPA médio por faixa de faltas

Faixa de Faltas	GPA Médio	Qtd. Alunos
0–10 faltas	2,8569	845
11–20 faltas	1,8108	846
21–30 faltas	0,8753	701

Variável mais crítica: A diferença de GPA entre alunos com poucas faltas (2,86) e alunos com muitas faltas (0,88) é de **1,98 pontos** — a maior variação observada em todo o dataset.

8.10 Perfil dedicado: estudo ≥ 10 h/semana E faltas ≤ 10

Perfil	GPA Médio	Qtd. Alunos
Dedicado (estudo ≥ 10 h e faltas ≤ 10)	2,9897	409
Demais alunos	1,6827	1.983

Alunos "dedicados" têm GPA médio **77,7% superior** ao restante da turma.

8.11 Correlação de Pearson com GPA

Variável	Correlação com GPA	Interpretação
Absences	−0,9193	Correlação negativa muito forte
ParentalSupport	+0,1908	Correlação positiva fraca
StudyTimeWeekly	+0,1793	Correlação positiva fraca
Tutoring	+0,1451	Correlação positiva fraca
Extracurricular	+0,0941	Correlação positiva muito fraca
Music	+0,0733	Correlação positiva muito fraca
Sports	+0,0579	Correlação positiva muito fraca
Volunteering	+0,0033	Sem correlação relevante

Variável	Correlação com GPA	Interpretação
Age	+0,0003	Sem correlação
ParentalEducation	-0,0359	Sem correlação relevante

Conclusão estatística: `Absences` é, de longe, a variável com **maior poder preditivo** sobre o GPA (correlação de -0,92), muito superior a todas as outras variáveis do dataset.

9. Validação das Hipóteses

H1 — Mais horas de estudo → melhor GPA

Status:  CONFIRMADA (parcialmente)

GPA cresce progressivamente com as horas de estudo: de 1,69 (0–5h) a 2,11 (15–20h). Porém, a correlação de Pearson é de apenas +0,18, indicando uma relação positiva mas moderada. O efeito isolado do estudo é muito menor do que o efeito das faltas.

H2 — Maior frequência → notas mais altas

Status:  CONFIRMADA (fortemente)

Alunos com 0–10 faltas têm GPA médio de 2,86, enquanto alunos com 21–30 faltas têm GPA médio de 0,88. A correlação de -0,92 entre `Absences` e GPA é a mais forte observada no dataset.

H3 — Extracurricular → melhor engajamento e GPA

Status:  CONFIRMADA (fracamente)

Alunos com atividades extracurriculares têm GPA médio ligeiramente superior (2,02 vs 1,84), com correlação de +0,09. O efeito existe mas é pequeno.

H4 — Maior suporte parental → melhores resultados

Status:  CONFIRMADA

Existe uma progressão clara: GPA cresce de 1,54 (sem suporte) a 2,19 (suporte muito alto). A correlação é de +0,19, a mais forte depois de `Absences`.

H5 — Educação dos pais influencia o desempenho

Status:  NÃO CONFIRMADA

Surpreendentemente, não há uma progressão clara. O GPA médio oscila entre 1,81 e 1,94 sem tendência definida, e a correlação é de apenas $-0,04$. A educação formal dos pais não se traduz em diferença significativa de GPA neste dataset.

H6 — Histórico de faltas → maior risco de baixo desempenho

Status:  CONFIRMADA (fortemente)

Mesma evidência da H2, vista pelo ângulo de risco: alunos com 21–30 faltas têm GPA médio de 0,88, quase inevitavelmente na classe F. É o principal indicador de risco identificado.

H7 — Idade do aluno influencia o desempenho

Status:  NÃO CONFIRMADA

GPA médio por idade: 15 anos (1,90), 16 anos (1,91), 17 anos (1,93), 18 anos (1,89). As diferenças são mínimas e a correlação é de $+0,0003$ — praticamente nula.

H8 — Estudo + frequência → notas mais altas

Status:  CONFIRMADA (fortemente)

Alunos dedicados (estudo ≥ 10 h/semana E faltas ≤ 10) têm GPA médio de 2,99, contra 1,68 dos demais — diferença de 1,31 pontos. A combinação das duas variáveis é muito mais preditiva do que cada uma isoladamente.

H9 — Combinação hábitos + suporte familiar é fator principal

Status:  CONFIRMADA (parcialmente)

As três variáveis mais correlacionadas com GPA são: **Absences** ($-0,92$), **ParentalSupport** ($+0,19$) e **StudyTimeWeekly** ($+0,18$). A combinação delas explica a maior parte da variância no desempenho. A hipótese está correta quanto à relevância combinada, embora **Absences** domine isoladamente.

H10 — Aulas particulares → maior rendimento

Status:  CONFIRMADA

Alunos com tutoria têm GPA médio de 2,11, contra 1,82 dos sem tutoria — diferença de 0,29 pontos. A correlação é de $+0,15$, confirmando o efeito positivo das aulas particulares.

Resumo da validação

Hipótese	Status	Força
H1 — Horas de estudo	✓ Confirmada	Fraca a moderada
H2 — Frequência escolar	✓ Confirmada	Muito forte
H3 — Extracurricular	✓ Confirmada	Fraca
H4 — Suporte parental	✓ Confirmada	Moderada
H5 — Educação dos pais	✗ Não confirmada	—
H6 — Faltas e risco	✓ Confirmada	Muito forte
H7 — Idade	✗ Não confirmada	—
H8 — Estudo + frequência	✓ Confirmada	Forte
H9 — Combinação de fatores	✓ Confirmada (parcial)	Moderada a forte
H10 — Aulas particulares	✓ Confirmada	Moderada

8 de 10 hipóteses confirmadas (80%)

10. Conclusão

Este projeto demonstrou na prática a aplicação da **Arquitetura Medalhão** em um problema educacional real, percorrendo todas as camadas do pipeline de dados:

O que foi alcançado

1. **Bronze:** Preservação fiel dos 2.392 registros originais, com rastreabilidade completa
2. **Silver:** Dados limpos, tipados, com colunas categóricas decodificadas e a variável sensível **Ethnicity** removida em conformidade com LGPD e princípios de fairness
3. **Gold:** 14 tabelas analíticas — 2 dimensionais, 1 fato e 11 KPIs — prontas para consumo por ferramentas de BI ou modelos de Machine Learning

Principal descoberta

A variável **Absences** (número de faltas) possui correlação de **-0,92** com o GPA, sendo o fator mais determinante do desempenho acadêmico neste dataset — muito acima de todas as outras variáveis. Isso sugere que **monitorar e intervir precocemente quando um aluno começa a faltar** é a ação mais eficaz que uma instituição pode tomar.

Recomendações de negócio

Recomendação	Indicador base
Implementar alerta automático quando aluno acumular > 10 faltas	Absences > 10 → GPA médio cai de 2,86 para 1,81
Ampliar programas de tutoria/reforço	Tutoria associada a +0,29 pontos de GPA
Fortalecer canais de comunicação escola-família	Suporte parental associado a +0,65 pontos de GPA (Nenhum → Muito Alto)
Criar programas de atividades extracurriculares	Extracurricular associado a +0,18 pontos de GPA

Próximos passos

- **Modelo preditivo:** Usar as tabelas Gold como base para treinar um classificador multiclasse (Random Forest, XGBoost) para prever **GradeClass**
- **Dashboard:** Conectar as tabelas Gold a uma ferramenta de BI (Power BI, Metabase) para monitoramento contínuo
- **Pipeline automatizado:** Substituir a execução manual dos notebooks por um orquestrador (Apache Airflow, Prefect) para atualização periódica dos dados

Relatório gerado em Abril de 2026 — Universidade do Oeste Paulista — Sistemas de Informação